

Devoir libre - Data Preprocessing

Le but de ce devoir est de familiariser les étudiants avec les étapes essentielles du prétraitement des données dans le cadre de l'analyse de données et de la construction de modèles de machine learning.

1. Trouver les variables manquantes

1.1- Lisez l'ensemble de données *titanic_survival.csv*

<https://drive.google.com/file/d/1GEnoAw3Ths0gyDPpqUQ7JWPmKj8n84o9/view?usp=sharing>

et affichez les premières lignes de l'ensemble de données pour observer sa structure.

- * Utilisez `pandas.read_csv()` pour charger les données.

- * Utilisez `head()` pour les premières lignes.

1.2- Quelle est la taille de ce dataset, les caractéristiques et la variable cible ? Y a-t-il des données manquantes ?

1.3- Compter le nombre de valeurs dans la colonne **age** possédant des valeurs manquantes :

- * Assigner à la variable **age** la colonne des âges du dataframe *titanic_survival*

- * Utiliser `pandas.isnull()` sur la variable âge pour créer une Series de valeurs True et False

- * Utiliser la Series résultante pour sélectionner seulement les éléments de la colonne age qui sont nuls et assigner le résultat à la variable **missing_values**

- * Assigner le nombre de valeurs manquantes de **missing_values** à la variable **missing_values_count** (fonction `len()`)

- * Afficher **missing_values_count** pour voir le nombre de valeurs manquantes de la colonne age.

1.4- Faire de même avec la colonne '**cabin**' avec l'instruction `isnull().sum()`

1.5- Compter les valeurs manquantes pour chaque colonne.

1.6- Discuter l'importance de gérer les données manquantes et les différents moyens de le faire.

2. Gérer les variables manquantes

2.1- Supprimer les lignes contenant des valeurs manquantes dans la colonne '**embarked**'.

2.2- Supprimer la colonne '**cabin**' du dataset.

2.3- Imputer les valeurs manquantes :

- *Imputation des variables numériques* : Remplacer les valeurs manquantes de la colonne '**age**' par la moyenne des âges.
- *Imputation des variables catégoriques* : Remplacer les valeurs manquantes de la : colonne '**embarked**' par la valeur la plus fréquente (mode). (Utilisez la stratégie '`most_frequent`')

3. Gérer les variables catégoriques

3.1- En considérant la variable '**embarked**' comme indépendante, appliquez l'encodage nécessaire (par exemple, LabelEncoder ou OneHotEncoder) pour remplacer la colonne '**embarked**' d'origine

dans le DataFrame_Titanic par les nouvelles colonnes encodées. Écrivez le code nécessaire pour effectuer cette opération et expliquez pourquoi l'encodage choisi est important pour cette variable.

3.2- En considérant la variable **sex** comme dépendante, appliquez l'encodage nécessaire à cette colonne pour qu'elle puisse être utilisée dans un modèle de machine learning.

4. Sélection des caractéristiques

4.1- Sélectionnez uniquement les colonnes **pclass**, **sex**, **age**, **fare**, et **survived** du dataset Titanic.

4.2- De manière générale, comment identifie-t-on les caractéristiques les plus importantes dans un dataset pour un modèle de machine learning ? Donnez des critères ou méthodes qui peuvent aider à ce choix.

4.3- Identifier et gérer les valeurs manquantes et les variables catégoriques.

5. Division de l'ensemble de données

5.1- Utilisez la fonction **train_test_split** de la bibliothèque sklearn pour diviser le dataset en un ensemble d'entraînement et un ensemble de test.

- La taille de l'ensemble de test doit être de (20%) de l'ensemble total.

- Fixez `random_state = 0` pour garantir que les résultats soient reproductibles.

5.2- Après la division, affichez la taille de chaque sous-ensemble (`X_train`, `X_test`, `y_train`, `y_test`).

5.3- Quel est l'intérêt principal de diviser les données entre un Training set et un Test set ? Expliquez comment cette division aide à éviter certains problèmes dans l'évaluation des modèles d'apprentissage automatique.

6. Feature Scaling

6.1- Ecrivez un code pour normaliser les caractéristiques de votre jeu de données d'entraînement et de test en utilisant à la fois **StandardScaler** et **MinMaxScaler** de la bibliothèque sklearn. Après avoir exécuté les deux normalisations, commentez les différences observées entre les deux méthodes en termes de plage des valeurs et d'effet sur la distribution des données.